

RAFIQUE NAZIR

AI ENGINEER

✉ rafique.nazir@protonmail.com
🌐 [LinkedIn](#) 🐙 [GitHub](#) 📁 [Portfolio](#)

🌟 **Zertifikate & Abzeichen**
👤 **Arbeitserlaubnis:** Niederlassungserlaubnis
📍 **Ort:** Darmstadt, Hessen, Deutschland



ZUSAMMENFASSUNG

- AI Engineer mit Fokus auf produktionsreife **Generative-AI**- und LLM-Systeme in **Python** auf **AWS**. Aktuelle Schwerpunkte sind Agenten-Tool-Orchestrierung über das **Model Context Protocol (MCP)**, die Übersetzung natürlicher Sprache in API-Aufrufe und LLM-Evaluierung.
- Mehr als zehn Jahre Backend-Erfahrung in verschiedenen Positionen, in der Entwicklung skalierbarer Microservices für Unternehmenskunden, überwiegend mit **Python** (FastAPI, Rasa) und **Java**.
- **AWS Certified Solutions Architect** mit Praxiserfahrung in Bedrock, EKS, **Kubernetes**, **Helm**, **Terraform** und GitLab CI/CD.
- Gewohnt, eigenständig zu arbeiten. Derzeit einziger Entwickler einer Enterprise-KI-Plattform, verantwortlich für Architektur, Umsetzung, Qualität, Deployment und Scoping.

BERUFSERFAHRUNG

BITA GmbH

AI Engineer

Frankfurt, Deutschland

01.2026 – heute

- Einziger AI Engineer in einem Projekt, das eine **Fintech-Plattform für Index-Erstellung** in ein konversationelles System überführt. Nutzer erstellen Anlageuniversen, definieren Methodologien und starten Backtests in natürlicher Sprache über KI-Agenten.
- Aufbau eines **Just-In-Time-Tool-Discovery**-Systems auf Basis des **Model Context Protocol (MCP)**, damit Agenten zur Laufzeit die passende Plattform-API finden und aufrufen. Die Tool-Suche läuft auf **ChromaDB** mit Titan-Embeddings.
- Entwurf der Schicht, die natürliche Sprache auf **AWS Bedrock** in API-Aufrufe übersetzt, mit schemabasierter Parameter-Extraktion, dokumentierten Defaults und Live-Abfrage der Plattform-Datenkataloge statt fest codierter IDs.
- Aufbau eines **LLM-as-a-Judge**-Evaluierungsframeworks und einer YAML-basierten Story-End-to-End-Suite, die Tool-Auswahl und Payload-Korrektheit prüft. Eine Story blockiert den Build erst, nachdem ihre Flake-Rate gemessen wurde.
- Einrichtung von Tracing und Kosten-Monitoring pro Modell mit **Langfuse** und **OpenTelemetry** sowie **Fallback-Ketten** und **I/O-Guardrails**, damit sich das System vorhersehbar verhält und Fehler verständlich meldet.
- Verantwortlich für die Delivery-Pipeline (**Helm** auf **AWS EKS**, GitLab CI mit Security-Scans, OAuth2/OIDC mit Cognito und Keycloak) sowie für Scoping, Aufwandsschätzung, API-Dokumentation und Demos auf C-Level.
- **Technologien:** Python, FastAPI, MCP, AWS Bedrock, AWS EKS, Langfuse, OpenTelemetry, ChromaDB, Redis, Docker, Helm, GitLab CI/CD, Pydantic, DeepEval, Gradio, Keycloak

Berufliche Auszeit (Weiterbildung)

Deutschland

09.2024 – 12.2025

- Geplante Auszeit für Weiterbildung in Vollzeit. Offizielle Deutschprüfungen **B1 und B2 (GER)** bestanden, die Zertifizierung **AWS Certified Solutions Architect (Associate)** erworben und LLM-Engineering-Kurse (RAG, Agenten, Fine-Tuning) abgeschlossen.

axxessio GmbH

Softwareentwickler

Darmstadt, Deutschland

01.2020 – 08.2024

- Wesentlicher Beitrag zu einem **sprachbasierten KI-Assistenten** für die Deutsche Telekom mit **Rasa** und **Python**, was zu einer **60%igen** Steigerung der Terminbuchungen beitrug.
- Entwicklung von Microservices und REST-APIs mit FastAPI sowie Integration von ML-Modulen und **spaCy**-basierter NLU in produktive Rasa-Pipelines.
- Performance mit **Redis-Caching** und PostgreSQL-Indexierung verbessert und API-Antwortzeiten um **40%** gesenkt; Aufbau von CI/CD und Infrastruktur mit **Kubernetes**, **Terraform** und **Helm**.
- Einarbeitung von Junior-Entwicklern (Dokumentation, Pair Programming) und enge Zusammenarbeit mit ML- und Produktteams.
- **Technologien:** Python, FastAPI, Rasa, spaCy, Redis, Kubernetes, Terraform, Helm, GitLab CI/CD, Azure, Docker, Pytest

Werkstudententätigkeiten

Software-/Webentwickler

Deutschland

08.2016 – 11.2019

- Bei **IDAT GmbH** ein Datenmigrationstool für SQL Server entwickelt und AutoCAD-Workflows automatisiert (C#, MS SQL Server, SSIS, tSQLt).
- Bei **arago GmbH** Testautomatisierung für die **HIRO-KI-Middleware** geschrieben (Java, JUnit, Oracle).
- Bei **asuro GmbH** Features für eine hybride mobile Versicherungs-App entwickelt (Ionic, Angular, TypeScript).

Vorherige Industriepositionen

Softwareentwickler

Karachi, Pakistan

08.2011 – 09.2015

- Bei **Connectcloud** als Senior Software Engineer an der Backend-Entwicklung von **UCloud** gearbeitet, einer software-definierten Cloud-Plattform, und eine Legacy-Desktop-Anwendung in eine moderne Webanwendung überführt (Java Spring, REST, AngularJS, MySQL).
- Bei **SofDigital Systems** ERP-Backend-Logik und Finanzberichte in den Produkten SmartERP und SmartHCM verbessert (ASP.NET, C#, NHibernate, Oracle PL/SQL, Crystal Reports).
- Bei **Game Ventures** Backend-Services für Howzat entwickelt, ein Echtzeit-Cricketspiel mit Mehrspielermodus (PHP, PostgreSQL, TDD).

TECHNISCHE KENNTNISSE

Sprachen & Frameworks	Python (FastAPI, Rasa, Gradio), Java (Spring Boot)
Generative AI & LLM-Agenten	Model Context Protocol (MCP, FastMCP), AWS Bedrock, Anthropic Claude, OpenAI API, LangChain, Ollama, Agenten-Orchestrierung, Function Calling, Prompt Engineering & -Management (Langfuse), RAG, Vektordatenbanken (ChromaDB, pgvector), Embeddings, hybride Suche & Reranking, Fine-Tuning (QLoRA), Guardrails
LLM-Evaluierung & LLMOps	LLM-as-a-Judge, DeepEval, Ragas, Retrieval-Metriken (MRR, nDCG, Recall@k), Halluzinations-Checks, E2E-Testsuiten
Async & Testing	asyncio, httpx; Pytest, TDD, pytest-mock, Ruff, MyPy, SonarQube
DevOps & Cloud	AWS (EKS, Bedrock, EC2, S3, Lambda, RDS, SQS, Cognito), Kubernetes, Docker, Terraform, Helm, GitLab CI/CD, GitHub Actions, Prometheus, Grafana, OpenTelemetry
Datenbanken & ORM	PostgreSQL, MongoDB, Redis; SQLAlchemy, Alembic, Hibernate/JPA
Daten & Messaging	Apache Kafka, RabbitMQ, Amazon SQS; Pandas, Polars, NumPy
Architektur	AI Solution Architecture, agentische KI, Microservices, eventgesteuerte Architektur, RESTful API Design, Cloud-native, Infrastructure as Code (IaC)
Sicherheit	OAuth2, JWT, OpenID Connect, RBAC, Keycloak, AWS Cognito
KI-gestützte Entwicklung	Tägliche Arbeit mit Claude Code und GitHub Copilot

ZERTIFIKATE

- AWS Certified Solutions Architect, Associate (08.2025) [Zertifikat anzeigen](#)
- AI Engineer Core Track: LLM Engineering, RAG, QLoRA, Agents, Udemy (2025)
- Professional Scrum Developer I, Scrum.org (03.2023) [Zertifikat anzeigen](#)
- ForgeRock Certified Access Management Specialist (07.2020)

STUDIUM

M.Sc. Distributed Software Systems

Technische Universität Darmstadt

10.2015 – 07.2019

Darmstadt, Deutschland

B.Sc. Computer Science

National University of Computer and Emerging Sciences

08.2007 – 06.2011

Karachi, Pakistan

Auszeichnung: Vierjähriges, leistungsbasiertes Vollstipendium des Ministeriums für IT, Pakistan.

SPRACHEN

Englisch: Verhandlungssicher • **Deutsch:** B2 (Deutsch-Test für den Beruf, 08.2025) • **Urdu & Sindhi:** Muttersprache